

CardioPredict S.A.: Sistema de Soporte para la Decisión Clínica (CDSS) mediante XGBoost y Arquitectura de Microservicios bajo la Ley 81

Josue Miranda
Universidad Latina de Panamá
Panamá, Panamá
josue.miranda@ulatina.edu.pa

Alanys Ortega
Universidad Latina de Panamá
Panamá, Panamá
alanys.ortega@ulatina.edu.pa

Adrian Herrera
Universidad Latina de Panamá
Panamá, Panamá
adeherrera@est.ulatina.edu.pa

Abstract—Este documento presenta el diseño, implementación y análisis de viabilidad de CardioPredict S.A., un Sistema de Soporte para la Decisión Clínica (CDSS) orientado a la estratificación de riesgo cardiovascular. El sistema integra un modelo de aprendizaje automático basado en XGBoost, optimizado para alcanzar una sensibilidad (Recall) del 85% y una precisión global del 81.97%, mitigando el riesgo de falsos negativos en el triaje médico. La solución cumple con la Ley 81 de 2019 (Panamá) mediante una arquitectura "Privacy by Design" sobre FastAPI. El análisis financiero a 5 años demuestra la rentabilidad del modelo SaaS con una TIR del 112%, validando su sostenibilidad en el sector HealthTech.

Index Terms—Ingeniería Biomédica, XGBoost, CDSS, Ley 81 Panamá, SaaS, Análisis Financiero, Sensibilidad Clínica, Salud Digital.

I. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) son la principal causa de mortalidad a nivel mundial. Para el ingeniero biomédico, la optimización del diagnóstico temprano es una prioridad. Este proyecto propone **CardioPredict S.A.**, una herramienta CDSS que cierra la brecha diagnóstica mediante Inteligencia Artificial, permitiendo a los profesionales de la salud realizar una estratificación de riesgo precisa y rápida en niveles de atención primaria, donde los recursos suelen ser limitados.

II. METODOLOGÍA Y ARQUITECTURA

A. Dataset y Preprocesamiento Clínico

Se utilizó el conjunto de datos de la UCI (Heart Disease Dataset), compuesto por **303 registros** con variables fisiológicas críticas como presión arterial, colesterol sérico y frecuencia cardíaca máxima. La variable objetivo es `HeartDisease`, con codificación binaria: Clase 0 (Sano) y Clase 1 (Enfermo). El dataset presenta un balance casi equitativo, con un 45.54% de casos sanos y un 54.46% de casos con enfermedad cardíaca, lo que favorece la capacidad

del modelo para aprender ambas clases sin sesgos severos de mayoría.

El conjunto se dividió de forma estratificada en **80% entrenamiento (242 muestras)** y **20% prueba (61 muestras)**, preservando la proporción original del target en cada partición: en el subconjunto de entrenamiento la distribución resultó en 45.45% Sano y 54.55% Enfermo, mientras que en el subconjunto de prueba fue de 45.90% y 54.10% respectivamente. Esta consistencia entre splits confirma que la estratificación fue aplicada correctamente. Adicionalmente, se empleó **Validación Cruzada Estratificada (Stratified K-Fold, K=5)** sobre el conjunto de entrenamiento durante la búsqueda de hiperparámetros, garantizando que cada fold mantenga la representatividad de ambas clases.

B. Modelo Predictivo (Optimización de Sensibilidad)

Se seleccionó **XGBoost** por su alta eficiencia en datos tabulares. Desde una perspectiva clínica, se priorizó el **Recall (Sensibilidad)** sobre el Accuracy absoluto, dado que en cardiología, omitir a un paciente en riesgo (falso negativo) representa un peligro crítico. El modelo fue optimizado mediante Grid Search con validación cruzada (K=5), convergiendo en los hiperparámetros: `learning_rate = 0.05`, `max_depth = 3` y `n_estimators = 100`.

Los resultados del K-Fold sobre el conjunto de entrenamiento se detallan en la Tabla I. La media de Accuracy entre folds fue del **80.15%** con una desviación estándar de $\pm 9.52\%$, lo cual refleja cierta variabilidad inherente al tamaño reducido del dataset (242 muestras de entrenamiento). Esta dispersión es esperada y no indica inestabilidad del modelo, sino la sensibilidad del estimador ante particiones pequeñas. El fold con mayor rendimiento alcanzó el 91.67% y el de menor rendimiento el 66.67%, estableciendo el rango de comportamiento del clasificador bajo distintas configuraciones de datos.

TABLE I
RESULTADOS DE K-FOLD CROSS VALIDATION (K=5) SOBRE EL
CONJUNTO DE ENTRENAMIENTO

Fold	Accuracy
Fold 1	73.47%
Fold 2	89.80%
Fold 3	66.67%
Fold 4	79.17%
Fold 5	91.67%
Media	80.15%
Desv. Estándar	±9.52%

C. Arquitectura de Software y Seguridad de Datos

La solución sigue un patrón de microservicios, integrando estándares de ciberseguridad médica:

- **Seguridad Legal:** Encriptación de datos sensibles alineada con la **Ley 81 de Protección de Datos (Panamá)**.
- **Backend:** FastAPI para una latencia <200ms, optimizando el flujo de trabajo clínico.
- **Interoperabilidad:** Diseño preparado para futura integración con estándares HL7/FHIR.

III. RESULTADOS DE IMPLEMENTACIÓN

La plataforma es funcional y está diseñada bajo principios de ingeniería de factores humanos para minimizar la carga cognitiva del facultativo.

A. Seguridad y Cumplimiento Normativo

El sistema de autenticación (Fig. 1) asegura que solo personal autorizado acceda a datos sensibles, utilizando tokens JWT y protocolos de encriptación que cumplen con estándares internacionales de salud digital.




Fig. 1. Interfaz de acceso seguro con cifrado de credenciales.

B. Interfaz Clínica y Usabilidad

El panel principal (Fig. 2) permite la entrada de parámetros fisiológicos de manera ergonómica, facilitando la toma de datos durante la consulta médica activa.




Fig. 2. Interfaz de captura de variables fisiológicas del paciente.

C. Motor de Inferencia y Soporte Diagnóstico

El sistema genera reportes inmediatos. La Fig. 3 muestra una alerta visual de riesgo. Esta salida no sustituye el juicio médico, sino que actúa como una "segunda opinión" basada en datos estadísticos masivos.




Fig. 3. Resultado del modelo indicando nivel de riesgo cardiovascular (72.3%).

D. Módulo de Sostenibilidad Económica

La viabilidad se gestiona mediante un módulo transaccional (Fig. 4), permitiendo a clínicas pequeñas acceder a tecnología de punta mediante un modelo de suscripción escalable.




Fig. 4. Confirmación de suscripción al servicio CDSS.

E. Evaluación del Modelo Predictivo

El modelo XGBoost alcanzó un **Accuracy del 85.25%** sobre el conjunto de prueba (61 muestras) y un **92.15%**

sobre el conjunto de entrenamiento (242 muestras), con una diferencia de 6.90 puntos porcentuales entre ambos. Esta brecha moderada indica que el modelo presenta un leve sobreajuste (*mild overfitting*), lo cual es esperable en datasets de tamaño reducido como el UCI Heart Disease; sin embargo, el rendimiento en test se mantiene sólido y generalizable. El **AUC-ROC** obtenido fue de **0.8755**, lo que clasifica al modelo como un discriminador de alta calidad según los estándares de evaluación clínica.

El desglose por clase en el conjunto de prueba (Tabla II) muestra que la clase “Enfermo” alcanzó un **Recall del 94%**, confirmando que el modelo identifica correctamente la gran mayoría de pacientes con riesgo cardiovascular real, minimizando los falsos negativos críticos en triaje. La clase “Sano” obtuvo una **Precisión del 91%**, lo que implica pocas alarmas falsas. El balance del target (54.10% Enfermo en test) favorece este resultado, dado que la clase mayoritaria recibe mayor representación durante el aprendizaje y el modelo puede optimizar su Recall sin comprometer severamente la Precisión global.

TABLE II
REPORTE DE CLASIFICACIÓN DEL MODELO XGBOOST — CONJUNTO DE PRUEBA

Clase	Precisión	Recall	F1-Score	Soporte
Sano	0.91	0.75	0.82	28
Enfermo	0.82	0.94	0.87	33
Accuracy	0.85			61
Macro Avg	0.86	0.84	0.85	61
Weighted Avg	0.86	0.85	0.85	61

La Matriz de Confusión (Fig. 5) permite visualizar directamente la distribución de predicciones correctas e incorrectas, mostrando que el modelo identifica correctamente la mayoría de los casos en ambas clases con un número reducido de errores.




Fig. 5. Matriz de Confusión del modelo XGBoost sobre el conjunto de prueba.

La Curva ROC (Fig. 6) cuantifica la capacidad discriminante del modelo con un AUC de 0.8755, respaldando su robustez en la separación entre pacientes sanos y enfermos a lo largo de distintos umbrales de decisión.




Fig. 6. Curva ROC del modelo XGBoost. AUC = 0.8755, indicando alta capacidad discriminante.

Finalmente, la Curva Precisión-Recall (Fig. 7) confirma que el modelo mantiene una precisión aceptable incluso al identificar la mayoría de los casos positivos, lo cual es prioritario en triaje cardiovascular donde minimizar falsos negativos es crítico.




Fig. 8. GANTT




Fig. 7. Curva Precisión-Recall. Alta área bajo la curva indica buen rendimiento en la detección de casos positivos.

IV. ANÁLISIS FINANCIERO Y VIABILIDAD

La sostenibilidad de CardioPredict S.A. se fundamenta en un modelo de negocio B2B con ingresos recurrentes. A diferencia de un SaaS convencional, un Sistema de Soporte para la Decisión Clínica (CDSS) exige una inversión inicial robusta en seguridad y validación técnica.

A. Desglose de la Inversión Inicial (CAPEX)

Para garantizar la integridad de los datos sensibles y el cumplimiento de la Ley 81 de 2019 (Panamá), se ha establecido una inversión inicial de **\$8,500.00 USD**. El desglose detallado se presenta en la Tabla III.

TABLE III
DESGLOSE DE INVERSIÓN INICIAL (CAPEX)

Categoría	Monto	Propósito en Ing. Biomédica
Cumplimiento Legal	\$2,500	Registro Ley 81 y protocolos HIPAA
Infraestructura Cloud	\$2,000	Alta disponibilidad y cifrado AES-256
Validación Clínica	\$1,500	Pruebas de campo y ajuste de métricas
Ingeniería de Factores	\$1,500	Diseño de UI/UX para evitar error médico
Marketing y Ventas	\$1,000	Adquisición de clientes B2B (Clínicas)
Total	\$8,500	Inversión Inicial Total

B. Infraestructura y Seguridad

Se ha seleccionado un despliegue en la nube (Cloud) sobre servidores locales. Esta decisión minimiza el gasto de capital en hardware y asegura que la plataforma cuente con redundancia geográfica, esencial para servicios de salud que requieren disponibilidad 24/7.

C. Indicadores de Rentabilidad

Considerando una tasa de descuento del 15% y los costos operativos ajustados, CardioPredict presenta una solvencia destacada (Ver Tabla IV).

TABLE IV
INDICADORES DE RENTABILIDAD PROYECTADOS

Indicador Financiero	Resultado
VAN (Valor Actual Neto)	\$82,415.00 USD
TIR (Tasa Interna de Retorno)	112%
Periodo de Recuperación (Payback)	1.1 Años (13 meses)

V. CONCLUSIÓN Y ROADMAP

Como ingenieros biomédicos, CardioPredict S.A. representa una solución técnica y económicamente viable para la modernización del triaje clínico. La integración de normativas de privacidad y el enfoque en la sensibilidad del modelo lo hacen apto para el mercado actual. El modelo XGBoost demostró un rendimiento sólido con un Accuracy del 85.25% en prueba, un AUC-ROC de 0.8755 y un Recall del 94% para la clase de riesgo, métricas que validan su aplicabilidad clínica. La diferencia de 6.90 puntos porcentuales entre train y test refleja un leve sobreajuste esperable en datasets pequeños, situación que se prevé reducir con la validación clínica en centros de salud locales y la obtención de la certificación HIPAA para su expansión internacional.

REFERENCES

- [1] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. of 22nd ACM SIGKDD*, 2016.
- [2] WHO, "Cardiovascular diseases (CVDs) Fact sheet," 2024.
- [3] Gaceta Oficial, "Ley 81 de Protección de Datos Personales," República de Panamá, 2019.
- [4] EinGuterWaran, "Awesome SaaS Boilerplates," GitHub [Online].
- [5] Vercel Inc., "FastAPI Runtime on Vercel," [Online].
- [6] Checkout.com, "Testing Payments Resources," [Online].