

Aplicación de Visión por Computadora para el Monitoreo de Ejercicios: Estimación de Pose y Conteo Automatizado usando YOLOv7

1st Josue Miranda

Colegio de Ingeniería Biomédica
Universidad Latina de Panamá
Panamá, Panamá
josumiranda@est.ulatina.edu.pa

2nd Alanys Ortega

Colegio de Ingeniería Biomédica
Universidad Latina de Panamá
Panamá, Panamá
Almiortega@est.ulatina.edu.pa

Resumen—El presente proyecto explora la implementación de técnicas de Estimación de Pose (Pose Estimation) utilizando la arquitectura de aprendizaje profundo YOLOv7 para la automatización del conteo de repeticiones en ejercicios físicos, específicamente el Curl de Bíceps. A diferencia de los métodos tradicionales que requieren sensores portátiles (wearables), este enfoque utiliza visión por computadora no invasiva. Se implementó un algoritmo de lógica vectorial sobre un modelo pre-entrenado (yolov7-w6-pose.pt) ejecutado en un entorno de nube con aceleración por GPU (Google Colab T4). Los resultados demuestran la capacidad del sistema para detectar puntos clave del cuerpo humano en tiempo real (Keypoints) y calcular ángulos articulares para registrar repeticiones válidas con una velocidad de procesamiento promedio de 10 FPS.

Index Terms—YOLOv7, Visión por Computadora, Estimación de Pose, Fitness Digital, Rehabilitación, Pose Estimation, Deep Learning, Real-time Processing

I. INTRODUCCIÓN

En el ámbito de la rehabilitación física y el entrenamiento deportivo, la supervisión correcta de los movimientos es crucial para evitar lesiones y asegurar el progreso. Tradicionalmente, esto requiere la presencia constante de un experto humano. Sin embargo, el auge de la Inteligencia Artificial (IA) ha permitido el desarrollo de sistemas de *Biofeedback* visual.

Este proyecto se centra en el uso de Redes Neuronales Convolucionales (CNN) para identificar la estructura esquelética humana en video. Se seleccionó la arquitectura YOLOv7 (*You Only Look Once*, v7) debido a su equilibrio superior entre velocidad y precisión en comparación con modelos anteriores. El objetivo principal es desarrollar un sistema capaz de interpretar el movimiento de flexión de codo (Curl de Bíceps) y contabilizar las repeticiones automáticamente sin necesidad de sensores físicos adheridos al cuerpo.

II. METODOLOGÍA

La metodología se dividió en tres fases: Configuración del Entorno, Inferencia del Modelo y Desarrollo del Algoritmo de Conteo.

II-A. Arquitectura del Modelo

Se utilizó el modelo **YOLOv7-w6-pose**, una variante de YOLOv7 optimizada para la detección de puntos clave (*key-points*). Este modelo fue entrenado previamente en el dataset COCO, lo que le permite identificar 17 puntos anatómicos (hombros, codos, muñecas, caderas, rodillas, tobillos, etc.) con alta precisión.

- **Entrada:** Video digital estándar (RGB).
- **Salida:** Coordenadas (x, y) de los puntos articulares y un esqueleto visualizado.

II-B. Algoritmo de Lógica de Conteo (Inferencia)

No se realizó un re-entrenamiento (*fine-tuning*) desde cero, sino que se aplicó una técnica de Inferencia y Post-procesamiento. Se desarrolló un script en Python (`bicepcounter.py`) que opera bajo la siguiente lógica matemática:

1. **Detección de Puntos:** Se extraen las coordenadas del Hombro (P_1), Codo (P_2) y Muñeca (P_3).
2. **Cálculo del Ángulo:** Utilizando funciones trigonométricas, se calcula el ángulo formado en el codo entre el brazo y el antebrazo mediante la siguiente ecuación:

$$\theta = |\text{atan2}(y_3 - y_2, x_3 - x_2) - \text{atan2}(y_1 - y_2, x_1 - x_2)| \quad (1)$$

3. **Máquina de Estados:**

- **Estado DOWN (Abajo):** Si $\theta > 160^\circ$, el brazo se considera extendido.
- **Estado UP (Arriba):** Si $\theta < 30^\circ$ (flexión completa) y el estado previo era DOWN, se contabiliza una repetición ($Count + 1$).

II-C. Recursos Tecnológicos

El desarrollo experimental se llevó a cabo utilizando los siguientes recursos:

- **Hardware:** GPU NVIDIA Tesla T4 (vía Google Colab).
- **Software:** Python 3.12, PyTorch (con parches de seguridad `weights_only=False`), OpenCV para manipulación de video.

III. RESULTADOS

El sistema fue probado con secuencias de video de ejercicios de bíceps. A continuación se detallan las métricas de desempeño obtenidas durante la ejecución experimental.

III-A. Análisis Visual y Detección

El modelo logró identificar correctamente el esqueleto del sujeto en el 100 % de los cuadros (*frames*) donde el cuerpo era visible. La superposición gráfica (esqueleto de líneas de colores) se mantuvo estable incluso durante el movimiento rápido.

En las pruebas visuales (Fig. 1 y Fig. 2 hipotéticas), el sistema detecta correctamente el estado inicial de reposo y la transición al estado de flexión máxima, incrementando el contador únicamente al completar el ciclo.

III-B. Rendimiento Computacional

El procesamiento se realizó sobre un video de entrada de 779 cuadros.

- **Velocidad Promedio:** 10.237 FPS.
- **Tiempo de Inferencia:** El tiempo de respuesta permite aplicaciones *offline* o casi tiempo real en hardware de gama media.

Se generó exitosamente el archivo de salida `bicep_kpt.mp4` conteniendo la superposición de datos visuales.

IV. CONCLUSIONES

La implementación de YOLOv7 para la estimación de pose en ejercicios de fuerza demostró ser una alternativa viable y eficiente frente a sensores físicos. El algoritmo geométrico basado en ángulos articulares funcionó correctamente para filtrar movimientos falsos y contar solo las repeticiones que cumplen con el rango de movimiento completo. Este prototipo tiene un alto potencial de aplicación en tele-rehabilitación, permitiendo a los fisioterapeutas monitorear si los pacientes realizan sus ejercicios correctamente en casa de forma autónoma.

REFERENCIAS

- [1] Wang, C.-Y., Bochkovskiy, A., & Liao, H.-Y. M. (2022). "YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors". arXiv preprint arXiv:2207.02696.
- [2] T. Wen et al., Review of research on the instance segmentation of cell images", *Comput. Methods Programs Biomed.*, vol. 227, 2022.
- [3] Documentación oficial de PyTorch y OpenCV. <https://pytorch.org/>




Figura 1. entrenamiento completo




Figura 2. Prueba Visual del Antes




Figura 3. Prueba Visual del Después